

Airlock

ML 모델 구조를 자동으로 실험하고, 무엇을 남기고 무엇을 버릴지 규칙에 따라 고르는 리서치 에이전트.

An auto-research agent that runs ML structure experiments and decides, by rule, what to keep and what to drop.

Daytona 샌드박스에서 실행 · Nosana 오픈 모델로 설명 · DNSimple로 게시

Why Airlock?

Why Daytona?

개발 방식이 '스펙 드리븐'에서 '아웃풋 드리븐'으로 바뀌고 있습니다.

Development is moving from spec-driven to output-driven: generate many results first, then choose.

지금까지 · 스펙 드리븐

먼저 명세를 쓰고, 그대로 한 번 만든다.

결과가 나쁘면 명세부터 다시 씁니다. 만드는 비용이 비쌌기 때문에 한 번에 맞히려고 했습니다.

지금 · 아웃풋 드리븐

먼저 결과물을 여러 개 만들고, 그중에서 고른다.

생성 비용이 싸졌기 때문에 가능해진 방식입니다. 그래서 지금의 추세는 에이전트를 병렬로 많이 돌려 결과물을 빨리 만들고, 그중 하나를 고르는 것입니다. 예: Cursor 2.0은 한 작업에 에이전트를 최대 8개 병렬로 실행합니다.

하지만 결과물이 많아질수록, 고르는 사람이 힘들어집니다.

More outputs do not mean a better choice. Past a point, the person choosing gets worse, not better.

24종 → 3%

시식대에 잼 24종을 놓았을 때 구매율. 사람은 더 많이 모였지만(60%), 대부분 고르지 못하고 떠났습니다.

6종 → 30%

잼 6종일 때 구매율. 선택지가 적을수록 실제로 고릅니다.

– Iyengar & Lepper, 2000

100개

에이전트 100개가 낸 결과물 100개. 순위도 근거도 없이 사람 앞에 놓이면, 선택이 아니라 부담이 됩니다.

그렇다면 – 에이전트가 최적의 합의점까지 대신 찾아주면 어떨까? 에이전트가 쓸 수 있는 평가 함수만 있으면 가능합니다. 결과물을 사람에게 100개 보여주는 대신, 에이전트가 직접 점수를 재고 골라서 하나만 가져오는 것입니다.

에이전트가 많을수록 무조건 좋은가? 아닙니다. 적정선이 있습니다.

Is more agents always better? No – there is a right amount, and it depends on the task.

많을수록 좋다는 근거

"More Agents Is All You Need"

같은 LLM을 여러 개 띄워 답을 모아 투표만 해도, 에이전트 수가 늘수록 정확도가 올라갑니다. – Li et al., 2024

많으면 나빠진다는 근거


"Why Do Multi-Agent LLM Systems Fail?"

실제 멀티에이전트 프레임워크의 실패를 14가지 유형으로 분류했습니다. 큰 축 하나가 **에이전트 간 불일치** – 서로 합의를 못 합니다. 많아지면 노이즈가 되고, 합의점을 찾기 어려워집니다. – Cemri et al., 2025

적정선은 태스크마다 다릅니다. 그래서 Airlock은 "몇 개를, 어떤 조합으로 돌릴지"를 미리 정하지 않습니다. **평가 함수 하나로 매 라운드 결과를 측정하고, 그 결과에 따라 다음에 무엇을 돌릴지 스스로 바꿉니다** – 탐색 알고리즘 자체가 진화하는 **진화적 탐색**입니다.

이 방향의 대표가 Google DeepMind의 AlphaEvolve입니다 (2025년 5월).

AlphaEvolve: an LLM proposes candidates, an evaluator scores them, only the best survive to the next generation. It needs large-scale execution infrastructure – which is exactly what Daytona provides.



전제 조건

대규모 실행·평가 인프라

후보 수천 개를 실제로 실행해야 하므로 대규모 컴퓨팅이 있어야만 쓸 수 있었습니다. 일반 공개 서비스가 아니라 제한된 접근입니다.

DAYTONA가 채우는 빈자리

실험 하나 = 샌드박스 하나

Airlock은 후보마다 Daytona 샌드박스를 만들어 실행하고 지웁니다. SDK 호출 몇 줄이면 됩니다. 대규모 클러스터 없이 같은 구조의 진화적 탐색을 돌릴 수 있습니다.

ML 구조의 조합을 자동으로 실험하고, 규칙에 따라 다음 실험을 고릅니다.

한 번에 한 요인만 바꿔서 대조군과 비교합니다. 효과가 없다고 증명된 계열은 더 실험하지 않습니다. 비싼 실험 전에만 사람에게 묻습니다.

One factor changed per experiment, against a control. Families proven useless are sealed. A person is asked only before an expensive batch.



AlphaEvolve와 가장 큰 차이는 "무엇을 버리느냐"입니다.

가설 A가 실험에서 성적이 나빴습니다. A를 버려야 할까요? 대부분의 오토리서치와 AlphaEvolve는 버립니다(점수 낮은 후보 탈락). ML에서는 이게 틀린 경우가 많습니다. **A 혼자**는 나빠도, **A + B**는 좋을 수 있습니다. 아래는 실제 실행 기록입니다(숫자는 5-fold 교차검증 정확도).

Should a hypothesis that scored badly be dropped? Most auto-research (and AlphaEvolve) drops it. In ML that is often wrong: A alone can be bad while A + B is the best. Real ledger below.

logistic 단독	0.944 – 단일 모델 8개 중 3위 . 1위는 rf 0.963. 점수 높은 후보만 남기는 방식이라면 여기서 logistic은 탈락.
standardize + logistic	0.975 (+0.032) → 승격. 여기에 C=0.1 → 0.979 = 챔피언 (rf보다 +0.016). 3위였던 요인이 조합에서 1위가 됐습니다.
polynomial	logistic과 조합: -0.040 (손해) . gb와 조합: +0.011 (유지) . 첫 실패에서 polynomial을 버렸다면 gb의 이득을 놓쳤습니다.
reduction (kbest · pca)	logistic·gb·rf 각각과 조합해도, standardize 뒤에 붙여도 전부 기준 미달 → 그때서야 봉인 . 한 번의 실패로는 봉인하지 않습니다.

Airlock은 가설 간의 관계를 기록합니다. 요인 단독 / 2개 조합 / 3개 조합의 결과를 따로 두고, 조합이 실패했다는 이유로 요인을 버리지 않으며, 손해가 난 조합만 닫습니다. 그래서 다양한 가설이 계속 살아 있는 채로 최적해에 다가갑니다.

1,212개 구조 중에서 고르는 방법은 세 가지입니다.

Three ways to search 1,212 structures: run all of them, hand 100 agent outputs to a human, or choose which experiments to run.

GRID SEARCH

1,212

회 실험

전부 실행

모든 조합을 다 돌립니다. 정확하지만, 후보가 늘어나면 비용을 감당할 수 없습니다.

에이전트 병렬 실행

100

개 결과, 순위 없음

사람이 고름

에이전트 100개가 결과 100개를 냅니다. 순위도 근거도 없어서, 결국 사람이 다시 판단해야 합니다.

AIRLOCK · 실제 실행

43

회 실험 · 챔피언 1개


실험을 골라서 실행

후보마다 점수를 실제로 재고, 효과 없는 계열은 더 돌리지 않고, 사람에게는 비용을 알려주며 두 번 물었습니다. 결과 0.979 – 최고 단일 모델보다 +0.016.

실험 하나마다 Daytona 샌드박스 하나를 씁니다.

아래는 실제 실행 화면입니다. 첫 라운드의 실험 8개가 샌드박스 8개에서 동시에 시작됐습니다.

Real capture: the first round's 8 experiments start at once, in 8 Daytona sandboxes.



병렬 실행

라운드의 실험들이 동시에 시작됩니다. 실험 8개가 1개 걸리는 시간에 끝납니다.

공식 SDK

Daytona Python SDK로 **create** → **upload** → **exec** → **delete**. 실험이 끝나면 샌드박스는 삭제됩니다.


화면에서 확인

오른쪽 패널에 샌드박스 ID와 실행 시간이 표시됩니다. 결과마다 어떤 샌드박스에서 실행됐는지 기록됩니다.

무엇을 버릴지도 규칙으로 정합니다.


요인 하나를 버리려면 그 요인 단독 실험이 실패해야 합니다. 조합이 실패했다는 이유로는 버리지 않습니다.

A factor is dropped only when it fails on its own. A failed combination never drops the factors inside it.



규칙 1

조합(레시피)이 실패해도, 그 안에 들어간 요인 단독은 버리지 않습니다.




규칙 2

계열은 단독 실험, 2개 조합, 3개 조합이 모두 기준 미달일 때만 봉인합니다. 봉인된 계열은 다시 실험하지 않습니다.

3라운드 동안 개선이 없으면, 원인 후보 두 개를 세우고 둘을 가르는 실험을 고릅니다.

가장 그럴듯한 아이디어가 아니라, 두 설명 중 하나를 틀렸다고 판정할 수 있는 실험 중 가장 싼 것을 먼저 실행합니다.

After 3 rounds without improvement: two candidate causes, then the cheapest experiment that rules one of them out.



설명 A

국소 최적 – 현재 챔피언 주변을 조금 바꿔도 점수가 변하지 않는다.

설명 B

계열 비용 – 특정 계열이 들어간 조합은 전부 점수가 깎인다.

가르는 관찰

A가 맞을 때와 B가 맞을 때 결과가 서로 다른 실험 하나.


다음 실행

그런 실험 중 비용이 가장 낮은 것.

좋은 요소 둘을 합치면 나빠질 수 있습니다. 그것도 측정해서 기록합니다.

앙상블 점수가 구성 모델 하나의 점수보다 낮으면 "조합 손해"로 기록하고, 그 조합은 다시 실행하지 않습니다.

If an ensemble scores below one of its own members, that combination is recorded as harmful and never run again.



결과의 한 종류

$1 + 1 < 2$ 는 오류가 아니라 판정 결과입니다. 어떤 조합이 왜 나빴는지 이름과 이유가 남습니다.

실제 실행에서

실험 43회 중 **8개** 조합이 손해로 판정됐습니다. 조합만 닫히고, 그 안의 요인은 열려 있습니다.


다시 실행하지 않음

손해 기록에는 구성 모델 각각의 점수가 함께 남습니다. 다음 라운드가 같은 조합을 다시 시도하지 않습니다.

비싼 실험 전에만 사람에게 묻습니다. 비용과 기본값을 함께 보여줍니다.

아래는 실제 실행 화면입니다. 사람이 답하지 않으면 정해진 기본값으로 진행하고, 그 사실을 채팅에 남깁니다.

Real capture. The agent asks only before an expensive batch, with the cost and the default it will take if nobody answers.



질문

"reduction / scaling 레시피 8개를 Daytona에서 실행할까요?"

비용

실험 8회 • Daytona 샌드박스 4개 – 답하기 전에 먼저 계산해서 보여줍니다.

기본값

답이 없으면 기본값(실행)으로 진행하고, 채팅에 그렇게 했다고 기록합니다.


답

클릭 한 번: **실행** 또는 **건너뛰기**. 건너뛴 실험은 "거절"로 기록되고, "실패"로 기록되지 않습니다.

결과: **standardize + logistic (C=0.1) · 0.979**

점수는 5-fold 교차검증으로 측정한 값입니다. 모델이 매긴 점수가 아닙니다.

The score is measured 5-fold cross-validation accuracy – never a model's opinion.



+0.016

최고 단일 모델(rf 0.963) 대비

43

실행한 실험 수

1,212

전부 실행할 때 필요한 실험 수

137.7초

시작부터 종료까지 (Daytona 샌드박스 4개)

점수는 전부 held-out fold에서 측정합니다. LLM은 점수를 매기지 않습니다. LLM이 하는 일은 실험 기록을 근거로 "왜 실패했나"에 답하고 마무리 요약을 쓰는 것뿐입니다.

Daytona • Nosana • DNSimple 위에서 동작합니다.

Daytona

실행

모든 실험은 Daytona 샌드박스에서 실행됩니다.
공식 SDK로 생성·업로드·실행·삭제를 병렬로
처리합니다.

Nosana

오픈 모델

Nosana에 배포한 오픈 모델(OpenAI 호환 /v1)이
실험 기록을 근거로 "왜 실패했나"에 답하고 마무리
요약을 씁니다. 점수는 매기지 않습니다.

DNSimple

게시

끝난 실험의 리포트를 서브도메인에 게시합니다.
토큰을 설정하면 동작하는 선택 단계입니다.

코드 · 실행 영상 · README: github.com/yc9954/airlock

에이전트를 놀리지 않고, 실험을 골라서 합니다.